

학습을 통한 성장

이번 수업을 통해 기존에 파편적으로 알고 있던 퍼셉트론, 활성화 함수, 손실함수, CNN과 같은 뉴럴 네트워크 개념들을 보다 체계적으로 정리할 수 있었습니다. 이전에는 각각의 개념을 개별적으로 이해하는 수준이었다면, 이번 수업을 통해 이러한 요소들이 데이터 입력부터 모델 학습, 예측 결과 도출까지 하나의 흐름 안에서 어떻게 연결되는지 이해하게 되었습니다. 특히 데이터 전처리와 모델 경량화에 대해 새롭게 배웠습니다. 데이터의 스케일과 분포가 학습 안정성과 성능에 영향을 준다는 점을 알게 되었고, 실제 환경에 AI 모델을 적용하기 위해서는 정확도뿐만 아니라 모델 크기, 연산량, 메모리 사용량, 지연시간 같은 요소도 함께 고려해야 한다는 것을 배웠습니다.

또한 모델을 직접 학습시키고, 학습된 모델을 변환한 뒤 라즈베리파이와 같은 제한된 환경에서 실행해 보면서 AI 시스템 개발 과정을 이해할 수 있었습니다. 이를 통해 AI 개발은 단순히 모델을 만드는 데서 끝나는 것이 아니라, 실제 장치에서 안정적으로 동작하도록 배포하고 최적화하는 과정까지 포함한다는 점을 체감했습니다.

실습 진행 과정

1. object detection 실험



2. FP32 vs INT8 추론 100,000회 반복 비교 실험

	FP32	INT8
모델 size [bytes]	115,876	36,768
추론 시간 평균 [ms]	1.205	1.286
추론 시간 표준편차 [ms]	0.0621	0.0022
CPU 사용률 [%]	213.03	180.53
RAM 사용량 [MB]	44.077	44.038

➔ 모델의 사이즈가 작아 RAM 사용량의 큰 차이가 없음. 실제 실행 환경에서의 메모리 사용량 비중이 더 큼.