


1. 실습 내용 및 기말 프로젝트 개요

- 실습을 통해서 DenNet, ResNet을 TFlite 형식으로 변환 및 INT8 양자화를 통해 모델을 quantization 하는 방법을 학습했다. 추가로 QAT 방식을 적용하여 quantization을 하는 과정에서의 정확도 손실을 최소화하여 학습하였다.
- 기말 프로젝트로는 quantization과 orthogonal하게 적용할 수 있는 model 경량화 방법인 pruning을 적용하는 과정을 진행했다..

2. 프로젝트 결과

- 먼저, 모델 backbone은 QAT 학습이 된 ResNet50을 baseline으로 사용했다.
- Pruning 방법론에서 unstructured pruning과 structured pruning 방법을 비교하는 것을 목표로 세웠다.
- 먼저 unstructured pruning은 전체 weight에서 magnitude가 낮은 30%를 잘라냈고, 정확도의 손실이 거의 없으나 왼쪽과 같은 unstructured sparsity를 발생시켜 raspberry PI에서 이를 활용하기 어렵다.
- structured pruning은 batch norm layer의 평균이 낮은 채널 30%를 잘라냈고, 이를 바탕으로 실제 모델을 압축하여 Tflite file의 size를 압축할 수 있었다. 그러나, 정확도 손실이 커서 이를 보완하기 위하여 pruning 이전에 regularization을 적용하는 등의 방법이 필요할 것으로 생각된다.



	Baseline	Unstructured 30%	Structured 30%
Validation Acc.	98.53	98.71	64.77
Tflite size (Mb)	23.49	23.49	14.56